



Linear Discriminant Analysis (LDA)

Seminário de Estatística

Pós Graduação em Modelagem Computacional

Lorran de Araújo Durães Soares

November 25, 2024



LNCC

Laboratório Nacional de
Computação Científica



Table of Contents

1 Introdução

- ▶ **Introdução**
- ▶ Como funciona (2D)
- ▶ Hipóteses Implícitas
- ▶ Aplicações
- ▶ Considerações Finais
- ▶ Referências



LDA

1 Introdução

- O LDA é um método estatístico utilizado para redução de dimensionalidade e classificação. Seu objetivo principal é encontrar um espaço de características de menor dimensão, de modo que as classes de dados sejam mais separáveis.
- Isso é feito maximizando a variabilidade entre as classes e minimizando a distância entre as médias das classes;
- Reduz para no máximo $C - 1$ dimensões, onde C é o número de classes.



LDA

1 Introdução

- Também pode ser usado como classificador, projetando os dados e aplicando, por exemplo (no caso 2D), um threshold para determinar a separação.
- É útil em situações onde as classes são linearmente separáveis, como em problemas de reconhecimento de faces, processamento de texto, e bioinformática.



Table of Contents

2 Como funciona (2D)

- ▶ Introdução
- ▶ **Como funciona (2D)**
- ▶ Hipóteses Implícitas
- ▶ Aplicações
- ▶ Considerações Finais
- ▶ Referências




LDA

2 Como funciona (2D)

Projeta os dados de entrada para uma dimensão:

$$y = \mathcal{W}^T x$$

Como escolher o melhor \mathcal{W} ?



^aFonte: Acervo Pessoal



1 - Maximizando a distância entre as classes:

$$\mathbf{m}_1 = \frac{1}{N_1} \sum_{n \in \mathcal{C}_1} x_n, \quad \mathbf{m}_2 = \frac{1}{N_2} \sum_{n \in \mathcal{C}_2} x_n.$$

$$m_2 - m_1 = w^T (\mathbf{m}_2 - \mathbf{m}_1)$$


onde

$$m_k = w^T \mathbf{m}_k$$



Problemas:

- O vetor \mathcal{W} pode se tornar arbitrariamente grande;
- Pode não escolher a melhor direção que separe os dados:



a

^aFonte: Bishop - Pattern Recognition



2 - Minimizar variância dentro de cada classe:

$$\mathbf{s}_k^2 = \sum_{n \in C_k} (y_n - m_k)^2$$

Chegamos então ao critério de Fisher:

Critério de Fisher

$$\mathcal{J}(\mathcal{W}) = \frac{m_2 - m_1}{s_1^2 + s_2^2}$$



Em função de W fica:

$$\mathcal{J}(W) = \frac{W^T S_B W}{W^T S_W W}$$

Onde S_B é a matriz de covariância entre classes e é dada por:

$$S_B = (\mathbf{m}_2 - \mathbf{m}_1)(\mathbf{m}_2 - \mathbf{m}_1)^\top$$

E S_W é a matriz de covariância total dentro das classes, dada por:

$$S_W = \sum_{n \in \mathcal{C}_1} (\mathbf{x}_n - \mathbf{m}_1)(\mathbf{x}_n - \mathbf{m}_1)^\top + \sum_{n \in \mathcal{C}_2} (\mathbf{x}_n - \mathbf{m}_2)(\mathbf{x}_n - \mathbf{m}_2)^\top$$



Diferenciando com respeito a \mathbf{w} e igualando a zero, encontramos que $J(\mathbf{w})$ é maximizado por:

$$(\mathbf{w}^\top \mathbf{S}_B \mathbf{w}) \mathbf{S}_W \mathbf{w} = (\mathbf{w}^\top \mathbf{S}_W \mathbf{w}) \mathbf{S}_B \mathbf{w}$$

Que implica que:



$$\mathbf{w} \propto \mathbf{S}_W^{-1}(\mathbf{m}_2 - \mathbf{m}_1).$$

Generalização para mais classes segue o mesmo princípio.



LDA

2 Como funciona (2D)



¹Fonte: Bishop - Patter Recognition



Classificação

- Treshold = 0;
- Teorema de Bayes:

$$p(\mathbf{x} \mid \mathcal{C}_k) = \frac{1}{(2\pi)^{D/2}} \frac{1}{|\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}_k) \right\}.$$

$$p(\mathcal{C}_1 \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid \mathcal{C}_1)p(\mathcal{C}_1)}{p(\mathbf{x} \mid \mathcal{C}_1)p(\mathcal{C}_1) + p(\mathbf{x} \mid \mathcal{C}_2)p(\mathcal{C}_2)}$$



Classificação

$$p(\mathcal{C}_1 \mid \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + w_0) = \frac{1}{1 + \exp(\mathbf{w}^\top \mathbf{x} + w_0)}$$

Classifica a amostra na classe com a maior probabilidade a posteriori.



Table of Contents

3 Hipóteses Implícitas

- ▶ Introdução
- ▶ Como funciona (2D)
- ▶ **Hipóteses Implícitas**
- ▶ Aplicações
- ▶ Considerações Finais
- ▶ Referências



LDA

3 Hipóteses Implícitas

- Dados seguem uma distribuição normal multivariada;
- Classes com mesma matriz de covariância;
- Variáveis e características devem ser linearmente independentes;
- Funciona melhor com mais dados do que variáveis (N suficientemente grande).



Table of Contents

4 Aplicações

- ▶ Introdução
- ▶ Como funciona (2D)
- ▶ Hipóteses Implícitas
- ▶ **Aplicações**
- ▶ Considerações Finais
- ▶ Referências




LDA

4 Aplicações

Dados Sintéticos Normais



- 1000 dados
- test size = 0.2
- 95 % de acurácia no conjunto de treinamento
- 93 % de acurácia no conjunto de teste





LDA

4 Aplicações






LDA

4 Aplicações

Dados Sintéticos não Normais

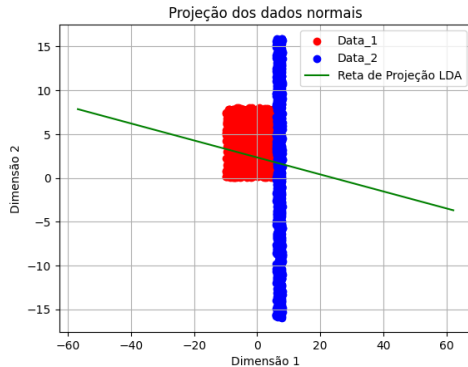

- Teste de não normalidade (Shapiro-Wilk com $\alpha = 0.5$):
 - Classe 1 - Dimensão 1: Estatística = 0.954, $p = 0.000$ Dimensão 2: Estatística = 0.954, $p = 0.000$
 - Classe 2 - Dimensão 1: Estatística = 0.959, $p = 0.000$ Dimensão 2: Estatística = 0.954, $p = 0.000$
- 1000 dados
- test size = 0.2
- 89 % de acurácia no conjunto de teste





LDA

4 Aplicações






LDA

4 Aplicações

Breast Cancer Database

- Teste de não normalidade (Shapiro-Wilk com $\alpha = 0.5$):
 - Classe 1: 28 dimensões não normais
 - Classe 2: 24 dimensões não normais
- 569 dados (212 malignos e 357 benignos)
- test size = 0.2
- 96 % de acurácia no conjunto de teste





LDA

4 Aplicações

Dados projetados na primeira componente do LDA






Table of Contents

5 Considerações Finais

- ▶ Introdução
- ▶ Como funciona (2D)
- ▶ Hipóteses Implícitas
- ▶ Aplicações
- ▶ **Considerações Finais**
- ▶ Referências



LDA

5 Considerações Finais

- Técnica poderosa para dados linearmente separáveis;
- Tomar cuidado ao usar esses métodos devido às hipóteses estatísticas;
- Compreendendo as hipóteses, é possível usar de forma eficaz.



Table of Contents

6 Referências

- ▶ Introdução
- ▶ Como funciona (2D)
- ▶ Hipóteses Implícitas
- ▶ Aplicações
- ▶ Considerações Finais
- ▶ Referências



LDA

6 Referências

- Bishop, C. M. (2006). Pattern Recognition and Machine Learning. Springer.
- Borges, M. R. (n.d.). GA-O3O Estatística. Laboratório Nacional de Computação Científica. <https://lncc.br/mrborges/>.
- Giraldi, G. A. (2024). Fundamentals of neural networks and statistical learning. Lecture Notes - Graduate Course, Graduate Program in Computational Modeling, PG-LNCC.



Linear Discriminant Analysis (LDA) *Thank*

you for listening!
Any questions?