# Classificacao Quantica de Imagens com Extratores Profundos de Caracteristicas

Proposta de investigacao: codificacao de estados, numero de qubits e classificadores quanticos variacionais

Lorran de Araujo Duraes Soares

Topicos Avancados de Redes Neurais Profundas e Aplicacoes
Laboratorio Nacional de Computacao Cientifica

3 de agosto de 2026

# Contextualização

## Modelos clássicos atuais

- Redes neurais convolucionais tem apresentado excelente desempenho em classificação de imagens.
- Entretanto, modelos totalmente clássicos podem exigir muitos parâmetros e grande capacidade computacional.

## Motivação quântica

- Circuitos quânticos exploram propriedades como superposição, interferência e emaranhamento;
- Ofere uma forma alternativa de representar e processar dados de alta dimensão.

## Questão de interesse

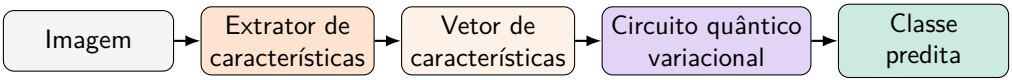
No cenário atual, uma abordagem prática é utilizar arquiteturas híbridas:

- uma CNN clássica extrai as características;
- um circuito quântico variacional realiza a classificação.

# Ideia Central

## Proposta

Desenvolver uma arquitetura híbrida composta por um extrator de características clássico e por circuitos quânticos variacionais utilizados como classificadores. Serão avaliados diferentes números de qubits e estratégias de codificação dos dados, com o objetivo de analisar seus impactos no desempenho da classificação de imagens.




## Pergunta orientadora

Como o número de qubits e a estratégia de codificação das características influenciam o desempenho de classificadores híbridos baseados em **circuitos quânticos variacionais** [**?** ] na classificação de imagens, quando comparados a um baseline clássico treinado sobre as mesmas características?

# Motivação

## Aprendizado profundo

Redes neurais convolucionais pré-treinadas são capazes de extrair representações visuais discriminativas e reutilizáveis, reduzindo a necessidade de treinar todo o modelo a partir do zero.

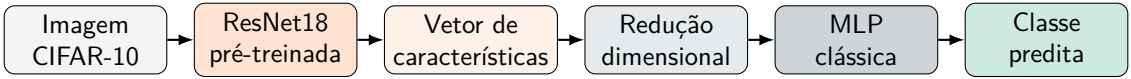
## Computação quântica

Circuitos quânticos parametrizados oferecem uma abordagem alternativa para codificar e transformar dados em espaços de Hilbert de alta dimensão [**?** **?** ].

## Arquitetura híbrida

A combinação de extratores clássicos com classificadores quânticos permite investigar o potencial dos circuitos variacionais sem transferir para o sistema quântico todo o custo do processamento visual.

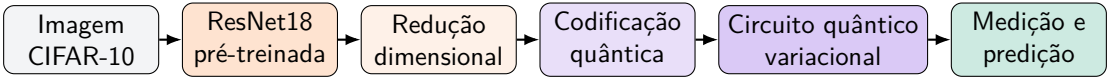
# Pipeline de Referência: Classificador Clássico




## Baseline experimental

O desempenho da MLP será utilizado como referência para avaliar a competitividade dos classificadores quânticos. Para garantir uma comparação justa, os modelos clássico e quântico receberão as mesmas características extraídas pela ResNet18 escolhida como extratora de características.

# Pipeline Proposto: Classificador Quântico




## Etapa clássica

A ResNet18 extrai representações visuais das imagens, enquanto a redução dimensional ajusta o vetor de características à quantidade de informações que pode ser codificada pelo circuito quântico.

## Etapa quântica

O vetor reduzido é codificado em um estado quântico e processado por camadas parametrizadas. As medições realizadas ao final do circuito são utilizadas para produzir a predição da classe.

## Ambiente de execução

Inicialmente, os circuitos quânticos serão executados em simuladores, permitindo avaliar diferentes configurações de qubits e estratégias de codificação em um ambiente controlado e livre de ruídos de hardware.

# Fundamentação: Qubits e Estados Quânticos

## Qubit

Diferentemente de um bit clássico, que assume os valores 0 ou 1, um qubit pode ser representado por uma superposição desses estados:

$$|\psi\rangle = \alpha\,|0\rangle + \beta\,|1\rangle\,,$$

em que $\alpha, \beta \in \mathbb{C}$ e

$$|\alpha|^2 + |\beta|^2 = 1.$$

## Sistema com múltiplos qubits

Um sistema com $n$ qubits é descrito em um espaço de dimensão $2^n$:

$$|\psi\rangle = \sum_{i=0}^{2^n-1} c_i\,|i\rangle\,,$$

com

$$\sum_{i=0}^{2^n-1} |c_i|^2 = 1.$$

Os coeficientes $c_i$ correspondem às amplitudes associadas aos estados da base computacional.

# Codificação de Dados em Estados Quânticos

## Interpretação para aprendizado de máquina

Os dados clássicos devem ser transformados em operações ou amplitudes compatíveis com um estado quântico. Esse processo é denominado **codificação dos dados**.

## Angle encoding

Cada característica controla o ângulo de uma porta de rotação:

$$|\psi(\mathbf{x})\rangle = \bigotimes_{i=1}^{n} R_y(x_i)\,|0\rangle\,.$$

- Implementação simples;
- Baixa profundidade;
- Em geral, uma característica por qubit e por camada.

## Amplitude encoding

As características são inseridas nas amplitudes do estado:

$$|\psi(\mathbf{x})\rangle = \sum_{i=0}^{2^n-1} x_i\,|i\rangle\,.$$

- Codifica até $2^n$ valores;
- Requer normalização;
- A preparação do estado pode ser custosa.

# Circuito Quântico Variacional

## Estrutura

Um circuito quântico variacional combina:

- uma etapa de codificação dos dados;
- portas parametrizadas;
- operações de emaranhamento;
- medições ao final do circuito.

Sua saída pode ser expressa como:

$$f_{\boldsymbol{\theta}}(\mathbf{x}) = \langle \psi(\mathbf{x}) | \, U^{\dagger}(\boldsymbol{\theta}) O U(\boldsymbol{\theta}) \, | \psi(\mathbf{x}) \rangle \, ,$$

em que $O$ é um observável quântico.

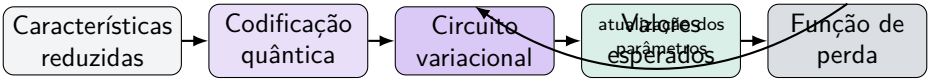
## Ansatz variacional

As camadas podem ser compostas por rotações parametrizadas e portas de emaranhamento:

$$U_{\text{var}}(\boldsymbol{\theta}) = U_{\text{ent}} \prod_{i=1}^{n} R_z(\theta_{i,3}) R_y(\theta_{i,2}) R_x(\theta_{i,1}).$$

- As rotações possuem parâmetros treináveis;
- As portas CNOT promovem emaranhamento;
- O bloco pode ser repetido por $L$ camadas.

# Treinamento do Modelo Híbrido




## Predição

Para cada qubit medido, pode-se calcular o valor esperado do observável de Pauli-$Z$:

$$z_i = \langle Z_i \rangle.$$

O vetor

$$\mathbf{z} = [\langle Z_1 \rangle, \ldots, \langle Z_m \rangle]$$

é utilizado para produzir a predição da classe.

## Otimização

A função de perda é calculada de forma clássica, e seus gradientes são utilizados para atualizar os parâmetros do circuito:

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} \mathcal{L}.$$

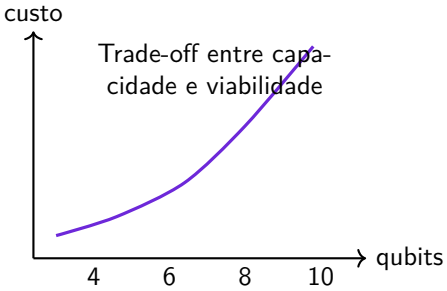
O gradiente pode ser obtido por métodos como a regra *parameter-shift*.

# Papel do Numero de Qubits

**Hipotese**

Mais qubits aumentam a capacidade de representacao do circuito, mas tambem aumentam custo de simulacao, risco de overfitting e dificuldade de otimizacao.

- Poucos qubits: classificador mais restrito.
- Mais qubits: maior espaco de estados.
- Simulacao classica cresce rapidamente.



# O que será comparado?

## Codificação dos dados

- Angle encoding
- Amplitude encoding
- Basis encoding
- Data re-uploading

## Número de qubits

- 4 qubits
- 6 qubits
- 8 qubits
- 10 qubits

## Circuito variacional

- Número de camadas
- Padrão de emaranhamento
- Número de parâmetros
- Profundidade do circuito

## Estratégia experimental

Cada fator será analisado de forma controlada, mantendo os demais componentes fixos, de modo a identificar sua influência individual sobre o desempenho do classificador.

# Desenho Experimental

1. Utilizar uma ResNet18 pré-treinada no ImageNet como extratora de características.
2. Manter os pesos da ResNet18 congelados durante os experimentos, garantindo que todos os classificadores utilizem o mesmo espaço de características.
3. Aplicar um método de redução ou projeção dimensional para adequar o vetor de características ao número de qubits e à estratégia de codificação avaliados.
4. Treinar circuitos quânticos variacionais para diferentes combinações de número de qubits, forma de codificação e arquitetura do circuito.
5. Treinar uma MLP clássica como baseline, utilizando as mesmas características reduzidas, os mesmos conjuntos de treino, validação e teste e condições experimentais equivalentes.
6. Comparar os modelos com base no desempenho preditivo, no custo computacional, no número de parâmetros e na estabilidade entre diferentes execuções.

## Controle experimental

Para garantir uma comparação justa, todos os modelos utilizarão os mesmos dados, a mesma divisão entre treino, validação e teste e as mesmas características extraídas pela rede convolucional antes da etapa de classificação.

# Metricas e Criterios de Analise

## Desempenho preditivo

- Acuracia
- Loss de validacao/teste
- Matriz de confusao
- Media e desvio entre folds

## Custo e estabilidade

- Tempo de treinamento
- Numero de parametros
- Numero de qubits
- Profundidade do circuito
- Variabilidade entre execucoes

# Hipoteses de Pesquisa

## H1: codificacao importa

Diferentes estrategias de codificacao podem produzir desempenhos distintos mesmo quando o extrator classico e mantido fixo.

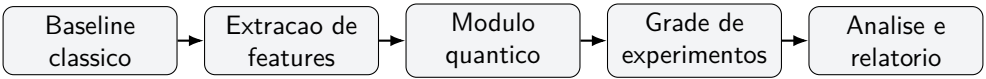
## H2: mais qubits nem sempre e melhor

O aumento do numero de qubits pode melhorar expressividade, mas tambem tornar a otimizacao mais dificil e aumentar custo computacional.

## H3: modelo hibrido pode ser competitivo

Um classificador quantico variacional pode se aproximar da MLP classica em alguns cenarios, especialmente com caracteristicas ja bem estruturadas.

# Etapas de Implementacao




- Integrar biblioteca quantica: PennyLane [**?** ] ou Qiskit Machine Learning.
- Criar interface comum para classificadores classico e quantico.
- Automatizar experimentos por codificacao, qubits e profundidade.

# Riscos e Limitacoes

## Computacionais

- Simulacao quantica pode ser lenta.
- Muitos qubits podem inviabilizar a grade completa.
- Amplitude encoding pode ter alto custo de preparacao.

## Metodologicos

- Comparacao precisa controlar splits e features.
- Resultados podem depender do ansatz escolhido.
- Ganho sobre MLP classica nao e garantido.

# Resultado Esperado da Proposta

## Produto tecnico

Um pipeline experimental hibrido capaz de comparar classificadores classicos e quanticos sobre as mesmas caracteristicas profundas extraidas de imagens.

## Produto cientifico

Uma analise empirica sobre como a escolha da codificacao quantica e do numero de qubits afeta desempenho, custo e estabilidade em classificacao de imagens.

## Entrega final

Codigo reprodutivel, tabelas comparativas, graficos de desempenho e discussao das limitacoes observadas.

# Referencias Iniciais


[] Ville Bergholm, Josh Izaac, Maria Schuld, et al. PennyLane: Automatic differentiation of hybrid quantum-classical computations. *arXiv preprint arXiv:1811.04968*, 2018.

[] Jacob Biamonte, Peter Wittek, Nicola Pancotti, Patrick Rebentrost, Nathan Wiebe, and Seth Lloyd. Quantum machine learning. *Nature*, 549:195–202, 2017.

[] M. Cerezo, Andrew Arrasmith, Ryan Babbush, et al. Variational quantum algorithms. *Nature Reviews Physics*, 3:625–644, 2021.

[] Maria Schuld, Ilya Sinayskiy, and Francesco Petruccione. An introduction to quantum machine learning. *Contemporary Physics*, 56(2):172–185, 2015.