Classificação Multiclasse de Imagens com Modelos Híbridos Clássico-Quânticos

Extratores profundos de características e circuitos quânticos variacionais

Lorran de Araújo Durães Soares

[1]Laboratório Nacional de Computação Científica (LNCC/MCTI)
lorran@posgrad.lncc.br

5 de agosto de 2026

LNCC
Laboratório Nacional de Computação Científica



Table of Contents

1 Introdução

▶ Introdução

▶ Fundamentação Teórica

▶ Metodologia

▶ Resultados Parciais

Modelos clássicos

- CNNs apresentam excelente desempenho em tarefas de classificação de imagens.
- Redes pré-treinadas podem extrair representações visuais robustas e reutilizáveis.
- As características extraídas podem ser fornecidas a diferentes classificadores.

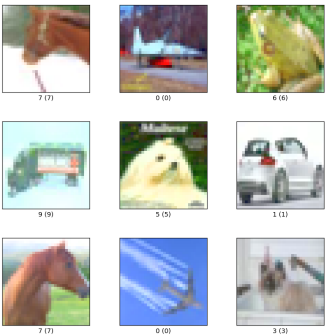


Figura: Exemplo de imagens do dataset Cifar10.



Motivação do estudo

1 Introdução

Circuitos quânticos variacionais

- Codificam dados clássicos em estados quânticos.
- Aplicam transformações unitárias parametrizadas, cujos parâmetros podem ser ajustados durante o treinamento.
- Produzem saídas por meio da medição de observáveis quânticos.

Abordagem híbrida

A proposta combina as capacidades complementares dos paradigmas clássico e quântico. Uma CNN pré-treinada extrai representações visuais compactas e robustas, enquanto um circuito quântico variacional atua como classificador sobre essas características. Essa arquitetura híbrida permite investigar se transformações quânticas parametrizadas, baseadas em superposição, interferência e emaranhamento, podem alcançar desempenho competitivo, considerando as limitações atuais de qubits e de profundidade dos circuitos.

Desafio experimental

O desempenho de um classificador quântico depende de diferentes escolhas de projeto, como:

- o número de qubits;
- a estratégia de codificação das características;

Essas escolhas devem ser avaliadas de forma controlada e comparadas com um baseline clássico competitivo.

Ideia central

Proposta

Avaliar diferentes configurações de classificadores quânticos variacionais, variando o número de qubits e a estratégia de codificação, e comparar seus resultados com uma MLP clássica treinada sobre as mesmas características reduzidas dimensionalmente e sob as mesmas condições experimentais.

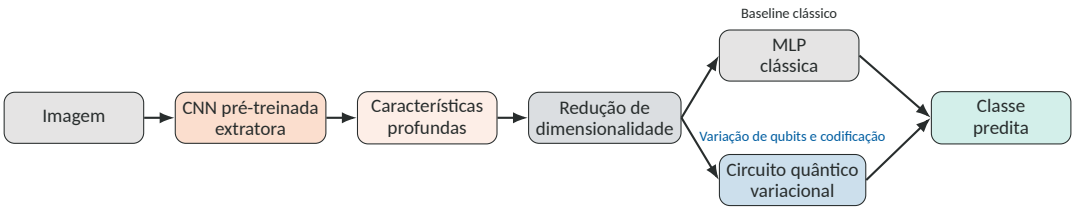




Table of Contents

2 Fundamentação Teórica

- ▶ Introdução
- ▶ Fundamentação Teórica
- ▶ Metodologia
- ▶ Resultados Parciais

Fenômenos em escala microscópica

Em escalas extremamente pequenas, partículas como elétrons, átomos e fótons podem apresentar comportamentos que não aparecem na física clássica, como superposição, interferência, emaranhamento e resultados probabilísticos na medição.

Do fenômeno físico ao processador

Em um processador quântico, sistemas físicos microscópicos são controlados para representar qubits. Pulsos eletromagnéticos, lasers ou outros mecanismos físicos são utilizados para preparar estados, aplicar portas quânticas e realizar medições.

Ideia central

A computação quântica consiste em controlar e repetir esses fenômenos de forma organizada, compondo operações em circuitos para realizar uma tarefa computacional específica.

$$\text{preparação} \longrightarrow \text{operações quânticas} \longrightarrow \text{interferência} \longrightarrow \text{medição}$$



Qubit: Estado e Medição [4]

Do bit ao qubit

Um bit clássico assume um estado bem definido:

$$0 \qquad \text{ou} \qquad 1.$$

Um qubit, por outro lado, é representado por

$$|\psi\rangle = \alpha\,|0\rangle + \beta\,|1\rangle\,,$$

com

$$\alpha, \beta \in \mathbb{C}, \qquad |\alpha|^2 + |\beta|^2 = 1.$$

Medição na base computacional

Ao medir o estado $|\psi\rangle$, obtém-se um resultado clássico:

$$P(0) = |\alpha|^2, \qquad P(1) = |\beta|^2.$$

Após a medição, o estado passa a ser compatível com o resultado observado:

$$|0\rangle \qquad \text{ou} \qquad |1\rangle\,.$$

Amplitudes de probabilidade

Os coeficientes α e β não são probabilidades diretamente. Eles são amplitudes complexas, enquanto as probabilidades observáveis são obtidas por seus módulos ao quadrado.

Superposição durante a computação

Durante a execução de um circuito, portas quânticas transformam as amplitudes associadas aos estados da base.
Assim, o estado pode evoluir como

$$|\psi\rangle = \sum_i c_i \, |i\rangle \, ,$$

sem que seja necessário medir o sistema a cada operação.

Interferência entre amplitudes

Como as amplitudes podem possuir sinais e fases diferentes, elas podem se combinar:

- **construtivamente**, reforçando determinados estados;
- **destrutivamente**, reduzindo ou cancelando outros.

A interferência altera as probabilidades observadas ao final do circuito.

Papel nos circuitos quânticos

O processamento quântico não consiste apenas em manter vários estados em superposição. As portas controlam amplitudes e fases para produzir padrões de interferência que influenciam o resultado da medição.

Espaço de estados

Um sistema com n qubits é descrito por um vetor em um espaço de dimensão 2^n:

$$|\psi\rangle = \sum_{i=0}^{2^n-1} c_i \, |i\rangle \, ,$$

com

$$\sum_{i=0}^{2^n-1} |c_i|^2 = 1.$$

Cada coeficiente c_i é a amplitude associada a um estado da base computacional.

Composição de qubits

O estado conjunto é construído pelo produto tensorial:

$$|\psi_{AB}\rangle = |\psi_A\rangle \otimes |\psi_B\rangle \, .$$

Por exemplo:

$$|0\rangle \otimes |1\rangle = |01\rangle \, .$$

Exemplo: dois qubits

$$|\psi\rangle = c_{00} \, |00\rangle + c_{01} \, |01\rangle + c_{10} \, |10\rangle + c_{11} \, |11\rangle \, .$$

Uma medição produz apenas um dos resultados:

$$00, \quad 01, \quad 10, \quad 11.$$

Estados não separáveis

Em sistemas com múltiplos qubits, pode ocorrer uma correlação quântica que não pode ser descrita separando o estado de cada qubit.
Um exemplo é o estado de Bell:

$$|\Phi^+\rangle = \frac{1}{\sqrt{2}}\left(|00\rangle + |11\rangle\right).$$

Interpretação

Nesse estado, os resultados possíveis são:

$$P(00) = \frac{1}{2}, \qquad P(11) = \frac{1}{2}.$$

Os resultados $|01\rangle$ e $|10\rangle$ possuem probabilidade nula.

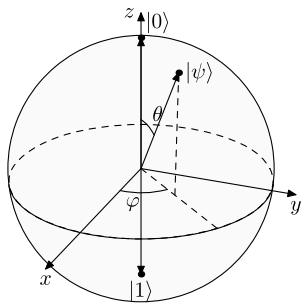
Consequência

Não é possível escrever o estado como

$$|\psi_A\rangle \otimes |\psi_B\rangle.$$

Portanto, o sistema deve ser descrito globalmente, e não como dois qubits independentes.

$$|\psi\rangle = \cos\left(\frac{\theta}{2}\right)|0\rangle + e^{i\phi}\sin\left(\frac{\theta}{2}\right)|1\rangle$$



Interpretação geométrica

Para um único qubit, cada estado puro pode ser representado como um ponto na superfície da **esfera de Bloch**. As portas de rotação são dadas por

$$R_x(\alpha) = \begin{pmatrix} \cos\left(\frac{\alpha}{2}\right) & -i\sin\left(\frac{\alpha}{2}\right) \\ -i\sin\left(\frac{\alpha}{2}\right) & \cos\left(\frac{\alpha}{2}\right) \end{pmatrix},$$

$$R_y(\beta) = \begin{pmatrix} \cos\left(\frac{\beta}{2}\right) & -\sin\left(\frac{\beta}{2}\right) \\ \sin\left(\frac{\beta}{2}\right) & \cos\left(\frac{\beta}{2}\right) \end{pmatrix},$$

$$R_z(\gamma) = \begin{pmatrix} e^{-i\gamma/2} & 0 \\ 0 & e^{i\gamma/2} \end{pmatrix}.$$

Essas operações correspondem a rotações do vetor de estado em torno dos eixos x, y e z, respectivamente.

O que é um observável?

Um observável é um operador Hermitiano que representa uma quantidade mensurável do sistema. Para um estado $|\psi\rangle$, sua saída é descrita pelo valor esperado

$$\langle O \rangle = \langle \psi | O | \psi \rangle ,$$

que corresponde à média dos resultados obtidos em várias execuções do circuito.

Por que usar observáveis em aprendizado de máquina?

Os observáveis convertem o estado quântico em valores clássicos reais, que podem ser usados como escores de classificação e no cálculo da função de perda. A escolha do observável determina qual informação do estado final será extraída.

Exemplo: observável Z

$$Z = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}.$$

Seus resultados possíveis são

$$|0\rangle \to +1, \qquad |1\rangle \to -1.$$

Assim,

$$\langle Z \rangle = P(0) - P(1) \in [-1, 1].$$

Sistemas com vários qubits

Para medir o qubit j, utiliza-se

$$Z_j = I^{\otimes(j-1)} \otimes Z \otimes I^{\otimes(n-j)}.$$

Podem ser obtidas saídas locais,

$$\langle Z_1 \rangle, \ldots, \langle Z_n \rangle,$$

ou correlações, como

$$\langle Z_1 Z_2 \rangle.$$

O que é PCA?

A Análise de Componentes Principais (*Principal Component Analysis*) é uma técnica linear de redução de dimensionalidade que transforma um vetor de características em um novo conjunto de variáveis não correlacionadas, chamadas de **componentes principais**.

Ideia principal

As componentes são ordenadas de acordo com a quantidade de variância dos dados que explicam:

$$\mathbf{x} \in \mathbb{R}^d \longrightarrow \mathbf{z} \in \mathbb{R}^k, \qquad k < d.$$

As primeiras componentes preservam as direções de maior variação do conjunto de dados.

Papel no modelo híbrido

A ResNet18 produz um vetor de características de alta dimensão. O PCA reduz esse vetor para uma dimensão compatível com a codificação quântica, buscando preservar a informação mais relevante antes da entrada no circuito.



Table of Contents

3 Metodologia

▶ Introdução

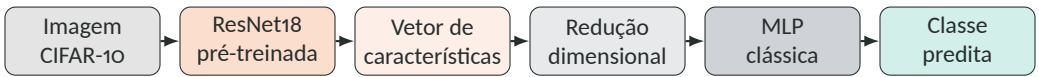
▶ Fundamentação Teórica

▶ Metodologia

▶ Resultados Parciais



Pipeline de Referência: Classificador Clássico



Baseline experimental

O desempenho da MLP será utilizado como referência para avaliar a competitividade dos classificadores quânticos. Para garantir uma comparação justa, os modelos clássico e quântico receberão as mesmas características extraídas pela ResNet18 escolhida como extratora de características. Além disso, esse modelo também será treinado recebendo a mesma quantidade de features que os modelos híbridos.



Arquitetura da MLP Clássica


```python
class MLPClassifier(nn.Module):
    def __init__(self, input_dim, config):
        super().__init__()

        self.network = _build_mlp(
            input_dim,
            config.get("hidden_layers", [256]),
            config.get("dropout", 0.3),
            config["num_classes"],
        )

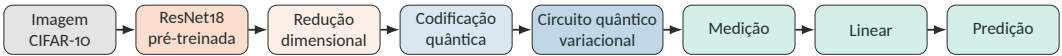
    def forward(self, features):
        return self.network(features)
```

Estrutura utilizada

A MLP recebe as características extraídas pela CNN e aplica uma ou mais camadas densas. Na configuração padrão, utiliza-se uma camada oculta com 256 neurônios, *dropout* de $0{,}3$ e uma camada de saída com um neurônio para cada classe.

Pipeline Proposto: Classificador Quântico

3 Metodologia



Etapa clássica

A ResNet18 extrai representações visuais das imagens, enquanto a redução dimensional ajusta o vetor de características à quantidade de informações que pode ser codificada pelo circuito quântico.

Etapa quântica

O vetor reduzido é codificado em um estado quântico e processado por camadas parametrizadas. As medições realizadas ao final do circuito são utilizadas para produzir a predição da classe [1, 3].

Ambiente de execução

Os circuitos quânticos serão executados em simuladores, permitindo avaliar diferentes configurações de qubits e estratégias de codificação em um ambiente controlado e livre de ruídos de hardware.

Interpretação para aprendizado de máquina

Antes de serem consumidos pelos circuitos quânticos variacionais, os dados clássicos devem ser transformados em operações ou amplitudes compatíveis com um estado quântico. Esse processo é denominado **codificação dos dados**.

Angle encoding

Cada característica controla o ângulo de uma porta de rotação:

$$|\psi(\mathbf{x})\rangle = \bigotimes_{i=1}^{n} R_y(x_i)\,|0\rangle\,.$$

- Implementação simples;
- Baixa profundidade;
- Em geral, uma característica por qubit e por camada.

Amplitude encoding

As características são inseridas nas amplitudes do estado:

$$|\psi(\mathbf{x})\rangle = \sum_{i=0}^{2^n-1} x_i\,|i\rangle\,.$$

- Codifica até 2^n valores;
- Requer normalização;
- A preparação do estado pode ser custosa.

Fluxo do circuito

Dado um vetor de características $\mathbf{x}$, o circuito realiza:

1. codificação dos dados nos n qubits;
2. aplicação de rotações parametrizadas;
3. criação de correlações por portas CNOT;
4. medição do observável Z em cada qubit.

O estado final é dado por

$$|\psi(\mathbf{x}, \boldsymbol{\theta})\rangle = U_{\text{var}}(\boldsymbol{\theta}) U_{\text{enc}}(\mathbf{x}) \, |0\rangle^{\otimes n}.$$

Ansatz variacional

Cada camada aplica, em cada qubit,

$$R_x(\theta_{\ell,i,1}), \qquad R_y(\theta_{\ell,i,2}), \qquad R_z(\theta_{\ell,i,3}),$$

seguida de portas CNOT entre qubits vizinhos.
A transformação de uma camada pode ser representada por

$$U^{(\ell)} = U_{\text{ent}} \prod_{i=1}^{n} R_z(\theta_{\ell,i,3}) R_y(\theta_{\ell,i,2}) R_x(\theta_{\ell,i,1}).$$

O bloco é repetido por L camadas:

$$U_{\text{var}} = U^{(L)} \cdots U^{(2)} U^{(1)}.$$

Saída quântica

Para cada qubit j, calcula-se

$$z_j = \langle \psi(\mathbf{x}, \boldsymbol{\theta}) | \, Z_j \, | \psi(\mathbf{x}, \boldsymbol{\theta}) \rangle \, ,$$

produzindo o vetor

$$\mathbf{z} = \left[\langle Z_1 \rangle, \ldots, \langle Z_n \rangle \right] \in [-1, 1]^n .$$

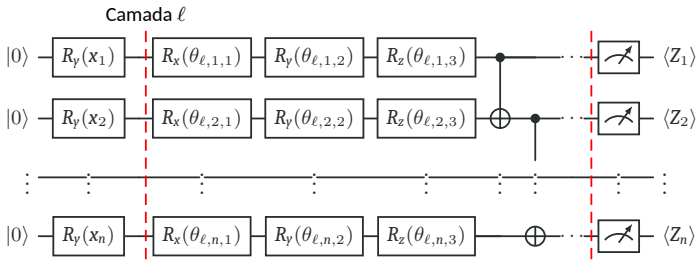
Classificação híbrida

O vetor de medições não representa diretamente as classes. Uma camada linear clássica realiza

$$\mathbf{o} = W\mathbf{z} + \mathbf{b},$$

gerando um logit para cada classe. Os parâmetros do circuito e da camada linear são treinados conjuntamente por retropropagação.

Ilustração do Circuito Quântico Variacional





Papel das rotações no circuito quântico

Rotações parametrizadas

Após a codificação, portas como

$$R_x(\theta), \quad R_y(\theta), \quad R_z(\theta)$$

transformam o estado quântico.
Durante o treinamento, seus ângulos são ajustados para produzir medições mais adequadas à tarefa de classificação.

Intuição para classificação

O treinamento busca levar amostras de classes diferentes a estados que produzam valores de medição mais distintos.

Emaranhamento

Portas como CNOT e CZ criam correlações entre os qubits, permitindo que o circuito processe conjuntamente diferentes características dos dados.

Saída do circuito

A medição de observáveis, como Z, produz valores em $[-1, 1]$ utilizados na classificação. Como cada execução fornece apenas uma amostra, o circuito é repetido por vários *shots* para estimar o valor esperado.



Treinamento do Modelo Híbrido

3 Metodologia

Fluxo de otimização

O circuito produz valores esperados que são enviados às camadas clássicas:

$$\mathbf{x} \longrightarrow f_{\boldsymbol{\theta}}(\mathbf{x}) \longrightarrow \mathcal{L}.$$

A função de perda é calculada classicamente, e um otimizador atualiza tanto os parâmetros quânticos quanto os parâmetros clássicos:

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} \mathcal{L}.$$

Regra *parameter-shift*

Para portas de rotação parametrizadas, o gradiente pode ser obtido avaliando o circuito em dois valores deslocados do parâmetro:

$$\frac{\partial f}{\partial \theta} = \frac{1}{2}\left[f\left(\theta + \frac{\pi}{2}\right) - f\left(\theta - \frac{\pi}{2}\right)\right].$$

Assim, não é necessário acessar diretamente o estado interno do hardware: o gradiente é estimado a partir de novas execuções do circuito.

Custo computacional

Para cada parâmetro treinável, a regra básica exige duas avaliações adicionais do circuito. Com P parâmetros, um passo de gradiente pode exigir aproximadamente $2P$ execuções, além da avaliação original.

Por que a retropropagação clássica não é aplicada diretamente?

Em uma rede neural clássica, os valores intermediários das camadas são armazenados e reutilizados no cálculo dos gradientes.
Em um computador quântico real:

- as amplitudes do estado não podem ser lidas diretamente;
- a medição altera o estado quântico;
- o hardware retorna apenas amostras ou valores esperados;
- não há acesso clássico aos estados intermediários do circuito.

Por isso, os gradientes são obtidos por novas execuções do circuito, utilizando métodos como *parameter-shift* [2].

Hardware quântico versus simulador

- **Hardware real:** o circuito é executado no processador quântico e os gradientes dependem de medições repetidas.
- **Simulador:** o estado pode ser armazenado numericamente, permitindo métodos como diferenciação por estado, método adjunto e, em alguns casos, aceleração por GPU.



Treinamento da Rede Híbrida

3 Metodologia

Algorithm 1: Fluxo de treinamento do modelo híbrido.

Input: Dados $\mathcal{D}$, ResNet18 pré-treinada, n qubits, L camadas e E épocas
Output: Parâmetros treinados $\boldsymbol{\theta}$, W e b

Congelar o extrator ResNet18;
Inicializar $\boldsymbol{\theta}$, W e b;
for $e \leftarrow 1$ **to** E **do**
  for *cada lote* $(\mathbf{I}, \mathbf{y})$ **do**
    $\mathbf{h} \leftarrow \mathrm{ResNet18}(\mathbf{I})$;
    $\mathbf{x} \leftarrow \mathrm{PCA/Projeção}(\mathbf{h})$;
    for *cada amostra* $\mathbf{x}_k$ **do**
      $|\psi_k\rangle \leftarrow U_{\mathrm{enc}}(\mathbf{x}_k)\,|0\rangle^{\otimes n}$;
      for $\ell \leftarrow 1$ **to** L **do**
        Aplicar R_x, R_y e R_z parametrizadas em cada qubit;
        Aplicar CNOTs entre qubits vizinhos;
      $\mathbf{z}_k \leftarrow [\langle Z_1\rangle, \ldots, \langle Z_n\rangle]$;
    $\mathbf{o} \leftarrow W\mathbf{z} + b$;
    $\mathcal{L} \leftarrow \mathrm{CrossEntropy}(\mathbf{o}, \mathbf{y})$;
    Calcular gradientes clássicos por retropropagação;
    Calcular gradientes quânticos por *parameter-shift*;
    Atualizar $\boldsymbol{\theta}$, W e b;



O que será analisado?

3 Metodologia

A estratégia de codificação influencia o desempenho

Mesmo com o extrator clássico mantido fixo, diferentes formas de codificar as características no circuito podem produzir resultados distintos: *Angle Encoding* e *Amplitude Encoding*.

Mais qubits não implica necessariamente melhor desempenho

O aumento do número de qubits amplia o espaço de estados e a capacidade de representação do circuito, mas também pode elevar o custo computacional e dificultar a otimização.
Serão avaliadas configurações com:

$$4, \quad 6 \quad \text{e} \quad 8 \text{ qubits.}$$

O modelo híbrido pode ser competitivo

Um classificador quântico variacional pode apresentar desempenho competitivo em relação a uma MLP clássica, especialmente quando recebe características visuais compactas e informativas extraídas por uma CNN pré-treinada.



Configurações de Treinamento

Dados, pré-processamento e rede

- Dataset: CIFAR-10 (32×32)
- Imagens redimensionadas para 224×224
- Divisão:

$$70\% \text{ treino}, \quad 15\% \text{ validação}, \quad 15\% \text{ teste}$$

- Tamanho do lote: 64
- Aumentos de dados:
  - recorte aleatório;
  - *color jitter* de $0{,}1$.
- ResNet18 pré-treinada na ImageNet
- Pesos do extrator congelados
- Redução de dimensionalidade por PCA

Otimização

- Otimizador Adam
- Taxa de aprendizado:

$$10^{-4}$$

- *Weight decay*:

$$10^{-4}$$

- Máximo de 500 épocas
- Agendador cossenoidal
- *Early stopping* com paciência de 8 épocas
- Lote quântico: 16



Table of Contents

4 Resultados Parciais

▶ Introdução

▶ Fundamentação Teórica

▶ Metodologia

▶ Resultados Parciais



Resultados I

4 Resultados Parciais

Redução	Codificação	Qubits	Parâmetros	Acurácia	Tempo (min)
PCA para 4	angle	4	74	**0.2584**	115.82
PCA para 6	angle	6	106	0.2781	462.62
PCA para 8	angle	8	138	0.3280	245.46
PCA para 16	amplitude	4	74	0.3976	99.09
PCA para 64	amplitude	6	106	**0.4233**	127.79
PCA para 256	amplitude	8	138	0.3941	542.99

Tabela: Resultados das configurações híbridas avaliadas, variando a estratégia de codificação e o número de qubits. O melhor resultado está destacado em verde e o pior em vermelho.



Resultados II

4 Resultados Parciais

Modelo	Features	Redução	Codificação	Qubits	Parâmetros	Acurácia	Tempo (min)
MLP	raw	Sem redução	–	–	133 898	0.8711	0.31
MLP	PCA	PCA para 4	–	–	3 850	0.5540	0.28
Híbrido	PCA	PCA para 4	angle	4	74	**0.2584**	115.82
MLP	PCA	PCA para 6	–	–	4 362	0.6428	0.21
Híbrido	PCA	PCA para 6	angle	6	106	0.2781	462.62
MLP	PCA	PCA para 8	–	–	4 874	0.7043	0.29
Híbrido	PCA	PCA para 8	angle	8	138	0.3280	245.46
MLP	PCA	PCA para 16	–	–	6 922	0.7855	0.51
Híbrido	PCA	PCA para 16	amplitude	4	74	0.3976	99.09
MLP	PCA	PCA para 64	–	–	19 210	0.8619	0.77
Híbrido	PCA	PCA para 64	amplitude	6	106	**0.4233**	127.79
MLP	PCA	PCA para 256	–	–	68 362	**0.8740**	0.44
Híbrido	PCA	PCA para 256	amplitude	8	138	0.3941	542.99

Tabela: Comparação entre os classificadores clássicos e híbridos em termos de dimensionalidade de entrada, número de parâmetros treináveis, acurácia no conjunto de teste e tempo de treinamento.

Evolução da loss

4 Resultados Parciais

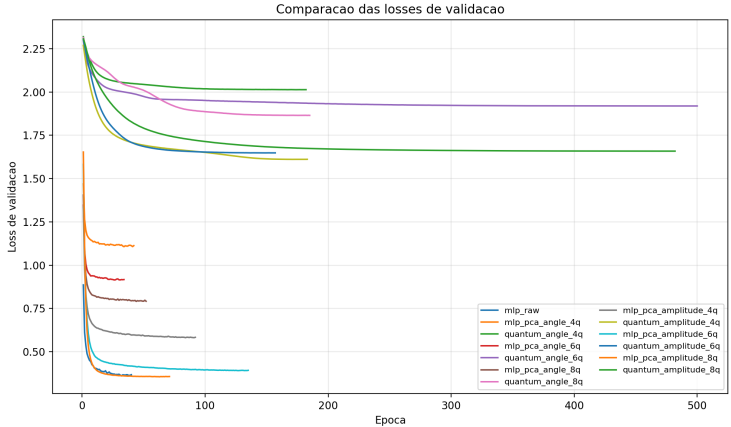


Figura: Evolução das funções custo no conjunto de validação.



Síntese dos Resultados

4 Resultados Parciais

- A MLP clássica apresentou o melhor desempenho geral.
- A codificação por amplitude superou a codificação angular entre os modelos híbridos avaliados.
- O aumento do número de qubits não produziu ganhos monotônicos.
- Os classificadores híbridos utilizaram poucos parâmetros treináveis, mas apresentaram custo de treinamento substancialmente maior.
- O melhor modelo híbrido utilizou amplitude encoding e 6 qubits, alcançando acurácia de 0.4233.



[1] Khadija Amadoun, Chaïmaâ Kissi, Amlan Chakrabarti, and Tarik Boujiha. An evaluation of pqc placement as feature extractor and classifier in hybrid quantum cnn and vit models on cifar-10. In *Nordic Conference on Digital Health and Wireless Solutions*, pages 687–705. Springer, 2026.

[2] Ville Bergholm, Josh Izaac, Maria Schuld, et al. PennyLane: Automatic differentiation of hybrid quantum-classical computations. *arXiv preprint arXiv:1811.04968*, 2018.

[3] M. Cerezo, Andrew Arrasmith, Ryan Babbush, et al. Variational quantum algorithms. *Nature Reviews Physics*, 3:625–644, 2021.

[4] Michael A Nielsen, Isaac L Chuang, et al. *Quantum computation and quantum information*, volume 1. Cambridge university press Cambridge, 2000.

Obrigado!

Perguntas e discussões

Classificação Multiclasse de Imagens com Modelos Híbridos Clássico-Quânticos

Extratores profundos de características e circuitos quânticos variacionais

---

Lorran de Araújo Durães Soares
lorran@posgrad.lncc.br