Calibração do Modelo de Rosenzweig-MacArthur com Algoritmos Genéticos e Redes Neurais

GB-500 - TEMC: Problemas Inversos Computacionalmente Intensivos: Implementação via Técnicas de Inteligência Artificial

Lorran de Araújo Durães Soares[1] - `lorran@posgrad.lncc.br`

[1]Laboratório Nacional de Computação Científica (LNCC/MCTI)

22 de outubro de 2026







Sumário

1 Introdução e Motivação

- ▶ Introdução e Motivação
- ▶ Definição do Problema Inverso
- ▶ Métodos de Identificação de Parâmetros
- ▶ Metodologia Experimental
- ▶ Estratégia de Avaliação
- ▶ Resultados Esperados e Desafios



Contextualização do Problema

1 Introdução e Motivação

- Modelos matemáticos baseados em **equações diferenciais ordinárias (EDOs)** são amplamente utilizados para descrever a evolução temporal de sistemas dinâmicos.
- A capacidade preditiva desses modelos depende da determinação adequada de seus **parâmetros**.
- A identificação desses parâmetros a partir de observações constitui um **problema inverso**, frequentemente formulado como um problema de otimização.
- Sua resolução pode apresentar desafios, como:
  - Sensibilidade ao ruído e às condições iniciais;
  - Não linearidade e mínimos locais;
  - Identificabilidade dos parâmetros;
  - Custo computacional.



Objetivos do Trabalho

Objetivo Geral

- Investigar e comparar diferentes técnicas de **identificação de parâmetros** em problemas inversos, utilizando o modelo de Rosenzweig-MacArthur como estudo de caso.

Objetivos Específicos

- Implementar um algoritmo genético para calibração de parâmetros;
- Investigar abordagens baseadas em **redes neurais**, incluindo redes neurais inversas e PINNs;
- Avaliar a capacidade de recuperação dos parâmetros a partir de dados sintéticos, com diferentes níveis de ruído;
- Comparar as técnicas quanto à **precisão, robustez, sensibilidade** e **custo computacional**.



Sumário

2 Definição do Problema Inverso

- ▶ Introdução e Motivação
- ▶ Definição do Problema Inverso
- ▶ Métodos de Identificação de Parâmetros
- ▶ Metodologia Experimental
- ▶ Estratégia de Avaliação
- ▶ Resultados Esperados e Desafios



Modelo de Rosenzweig-MacArthur

O modelo de **Rosenzweig-MacArthur** descreve a dinâmica entre presas e predadores, incorporando o crescimento logístico das presas e a resposta funcional de Holling tipo II.

Sistema de Equações Diferenciais

$$\begin{cases} \dfrac{dN}{dt} = rN\left(1 - \dfrac{N}{K}\right) - \dfrac{aNP}{1 + ahN}, \\ \dfrac{dP}{dt} = e\dfrac{aNP}{1 + ahN} - mP. \end{cases} \tag{1}$$

Em que $N(t)$ e $P(t)$ representam, respectivamente, as populações de presas e predadores.

- r: taxa de crescimento das presas;
- K: capacidade de suporte;
- a: taxa de ataque dos predadores;
- h: tempo de manipulação;
- e: eficiência de conversão;
- m: taxa de mortalidade dos predadores.

O vetor de parâmetros a ser identificado é:

$$\boldsymbol{\theta} = (r, K, a, h, e, m).$$



Geração dos Dados Sintéticos

2 Definição do Problema Inverso

- Definir um conjunto de parâmetros de referência:

$$\boldsymbol{\theta}^* = (r^*, K^*, a^*, h^*, e^*, m^*).$$

- Resolver numericamente o sistema de Rosenzweig-MacArthur, considerando condições iniciais conhecidas:

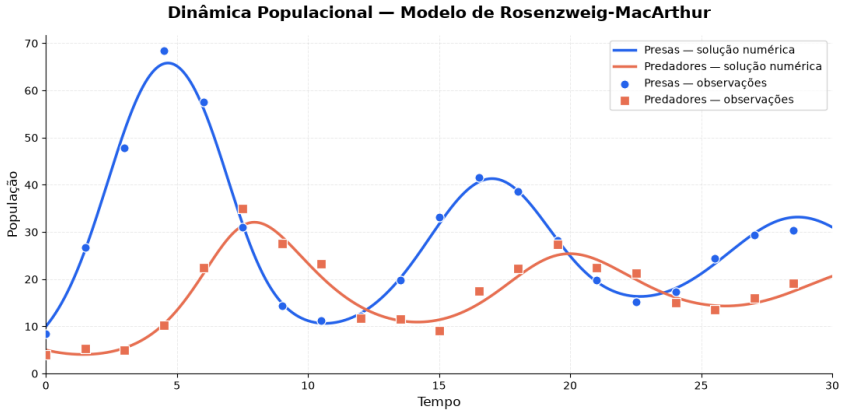
$$N(0) = N_0, \qquad P(0) = P_0.$$

- Amostrar as soluções em instantes discretos $t_1, t_2, \ldots, t_m$ e adicionar ruído:

$$N_i^{obs} = N(t_i; \boldsymbol{\theta}^*) + \varepsilon_{N,i},$$
$$P_i^{obs} = P(t_i; \boldsymbol{\theta}^*) + \varepsilon_{P,i}.$$

Geração de Dados Sintéticos

2 Definição do Problema Inverso



Considerar diferentes cenários experimentais:

- Dados sem ruído e com diferentes níveis de ruído;
- Diferentes quantidades de observações temporais;
- Diferentes conjuntos de parâmetros de referência.

Finalidade

Construir problemas inversos controlados, permitindo avaliar a capacidade de cada método em recuperar os parâmetros conhecidos.

Formulação do Problema Inverso

2 Definição do Problema Inverso

- Considere as observações disponíveis em m instantes de tempo:

$$\mathcal{D} = \left\{ (t_i, N_i^{obs}, P_i^{obs}) \right\}_{i=1}^{m}.$$

- O objetivo é identificar o vetor de parâmetros:

$$\boldsymbol{\theta} = (r, K, a, h, e, m),$$

cujas soluções numéricas melhor reproduzam as observações.

- Ω: conjunto admissível de parâmetros positivos;
- w_N, w_P: pesos para balancear os resíduos;
- $N(t;\boldsymbol{\theta}), P(t;\boldsymbol{\theta})$: soluções numéricas do modelo.

Problema de Otimização

$$\boxed{\boldsymbol{\theta}^{opt} = \arg\min_{\boldsymbol{\theta}\in\Omega} J(\boldsymbol{\theta})}$$

$$J(\boldsymbol{\theta}) = \frac{1}{m}\sum_{i=1}^{m}\left[w_N \left(N(t_i;\boldsymbol{\theta}) - N_i^{obs} \right)^2 + w_P \left(P(t_i;\boldsymbol{\theta}) - P_i^{obs} \right)^2 \right].$$

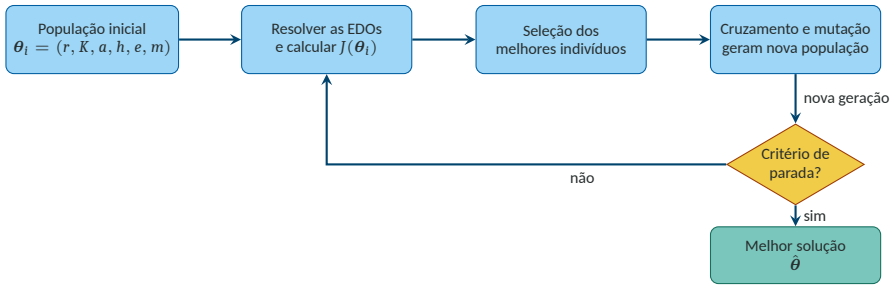


Sumário

3 Métodos de Identificação de Parâmetros

- ▶ Introdução e Motivação
- ▶ Definição do Problema Inverso
- ▶ Métodos de Identificação de Parâmetros
- ▶ Metodologia Experimental
- ▶ Estratégia de Avaliação
- ▶ Resultados Esperados e Desafios

O AG explora populações de parâmetros candidatos sem exigir o cálculo de derivadas da função objetivo.

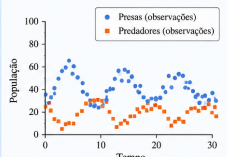


Redes Neurais para Problemas Inversos

3 Métodos de Identificação de Parâmetros

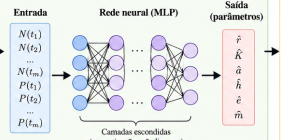
1 Dados observados

Séries temporais de presas e predadores (com ruído)



2 Rede neural para estimação de parâmetros

A rede neural recebe as séries temporais observadas (como um vetor) e estima os parâmetros do modelo de Rosenzweig-MacArthur.



3 Parâmetros estimados

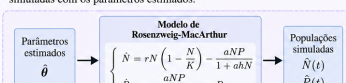
A rede neural fornece uma estimativa para os parâmetros do modelo:

$$\hat{\boldsymbol{\theta}} = (\hat{r}, \hat{K}, \hat{a}, \hat{h}, \hat{e}, \hat{m})$$

Parâmetro	Valor verdadeiro	Valor estimado
r	1.0	0.98
K	100.0	102.5
a	0.05	0.048
h	0.20	0.21
e	0.50	0.47
m	0.50	0.52

4 Treinamento da rede neural

Durante o treinamento, a rede aprende a minimizar o erro entre as populações observadas e as populações simuladas com os parâmetros estimados.

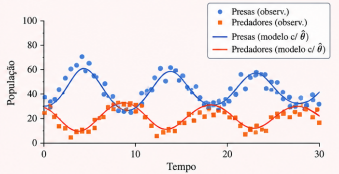


Função de perda (exemplo):

$$\mathcal{L} = \frac{1}{m}\sum_{k=1}^{m}\left[\left(N(t_k) - \hat{N}(t_k)\right)^2 + \left(P(t_k) - \hat{P}(t_k)\right)^2\right]$$

5 Validação do resultado

Com os parâmetros estimados, simulamos o modelo e comparamos com os dados observados.



Rede Neural Inversa: Dados e Características

3 Métodos de Identificação de Parâmetros

Dados utilizados

- Banco supervisionado de pares $(\mathbf{y}^{(j)}, \boldsymbol{\theta}^{(j)})$;
- Trajetórias geradas para diferentes parâmetros, condições iniciais e níveis de ruído;
- Separação em treino, validação e teste por vetores de parâmetros.

Vantagens

- Inferência rápida após o treinamento;
- Reutilizável para muitas trajetórias observadas;
- Não requer resolver as EDOs em cada nova estimação.

Limitações

- Banco de treinamento grande e representativo;
- Custo inicial de gerar trajetórias rotuladas;
- Generalização limitada fora do domínio treinado.

Uso no teste

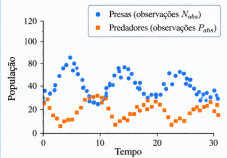
Uma nova trajetória observada, associada a parâmetros desconhecidos, é fornecida à rede para obter $\hat{\boldsymbol{\theta}}$.

Physics-Informed Neural Networks (PINNs)

3 Métodos de Identificação de Parâmetros

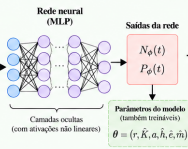
1 Dados observados

Observações ruidosas das populações de presas e predadores em instantes discretos de tempo.



2 PINN para estimação de parâmetros

Uma rede neural aproxima as populações $N(t)$ e $P(t)$ e, simultaneamente, os parâmetros do modelo $\boldsymbol{\theta} = (r, K, a, h, e, m)$ são tratados como variáveis treináveis.



3 Modelo físico (Rosenzweig-MacArthur)

As populações devem satisfazer o sistema de EDOs:

$$\begin{cases} \dot{N} = rN\left(1 - \dfrac{N}{K}\right) - \dfrac{aNP}{1 + ahN} \\ \dot{P} = e\,\dfrac{aNP}{1 + ahN} - mP \end{cases}$$

Definimos os resíduos físicos avaliados nos pontos de colocação t_j^f:

$$R_N(t_j^f) = \frac{dN_\phi}{dt}(t_j^f) - rN_\phi\left(1 - \frac{N_\phi}{K}\right) + \frac{aN_\phi P_\phi}{1 + ahN_\phi}$$

$$R_P(t_j^f) = \frac{dP_\phi}{dt}(t_j^f) - e\frac{aN_\phi P_\phi}{1 + ahN_\phi} + mP_\phi$$

4 Função de perda

A função de perda combina os termos de dados, condição inicial e físico:

$$\mathcal{L} = \mathcal{L}_{dados} + \lambda_f \mathcal{L}_{física} + \lambda_0 \mathcal{L}_{inicial}$$

Perda de dados Diferença entre as observações e as populações estimadas nos instantes observados t_i^{obs}.

$$\mathcal{L}_{dados} = \frac{1}{n_{obs}} \sum_{i=1}^{n_{obs}} \left[\left(N_\phi(t_i^{obs}) - N_{obs}(t_i^{obs})\right)^2 + \left(P_\phi(t_i^{obs}) - P_{obs}(t_i^{obs})\right)^2 \right]$$

Perda física Resíduo das equações diferenciais nos pontos de colocação t_j^f.

$$\mathcal{L}_{física} = \frac{1}{n_f} \sum_{j=1}^{n_f} \left[R_N(t_j^f)^2 + R_P(t_j^f)^2 \right]$$

Perda de condição inicial Imõe as condições iniciais (se conhecidas).

$$\mathcal{L}_{inicial} = \left(N_\phi(t_0) - N_0\right)^2 + \left(P_\phi(t_0) - P_0\right)^2$$

5 Treinamento da PINN

Os pesos da rede $\boldsymbol{\phi}$ e os parâmetros $\boldsymbol{\theta}$ são otimizados simultaneamente para minimizar a função de perda.

Otimização
(Adam, L-BFGS, etc.)

Saídas do treinamento

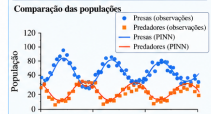
- Populações estimadas: $N_\phi(t)$, $P_\phi(t)$
- Parâmetros estimados: $\hat{\boldsymbol{\theta}} = (\hat{r}, \hat{K}, \hat{a}, \hat{h}, \hat{e}, \hat{m})$

6 Resultados

Parâmetros estimados

Parâmetro	Valor verdadeiro	Valor estimado
r	1.0	0.98
K	100.0	102.3
a	0.05	0.048
h	0.20	0.21
e	0.50	0.47
m	0.50	0.52

Comparação das populações



PINN Inversa: Dados e Características

3 Métodos de Identificação de Parâmetros

Dados utilizados

- Uma única série observada de presas e predadores;
- Condições iniciais conhecidas ou observadas;
- Pontos de colocação no tempo para impor as EDOs.

Vantagens

- Não exige banco prévio de trajetórias rotuladas;
- Integra observações e a física do modelo;
- Reconstrói trajetórias contínuas no tempo.

Limitações

- Novo treinamento para cada conjunto de observações;
- Custo elevado e sensibilidade aos pesos das perdas;
- Ruído e baixa identificabilidade dificultam a estimação.

Avaliação com dados sintéticos

O parâmetro verdadeiro é usado apenas para medir o erro de $\hat{\theta}$, e não como rótulo durante o treinamento.



Sumário

4 Metodologia Experimental

- ▶ Introdução e Motivação
- ▶ Definição do Problema Inverso
- ▶ Métodos de Identificação de Parâmetros
- ▶ Metodologia Experimental
- ▶ Estratégia de Avaliação
- ▶ Resultados Esperados e Desafios

Protocolo Experimental e Número de Otimizações

4 Metodologia Experimental

Cenários de teste

- Variar N_θ vetores de parâmetros, N_σ níveis de ruído e N_m quantidades de observações;
- Total de cenários:

$$N_c = N_\theta N_\sigma N_m;$$

- Repetir cada cenário R vezes, com sementes e inicializações distintas.

Execuções por método

Método	Por caso	Total
AG	Uma calibração evolutiva	$N_c R$
Rede neural inversa	Treino único; inferência nos testes	N_{NN}
PINN	Uma PINN por série observada	$N_c R$

Contagem total

$$N_{\text{otim}} = 2N_c R + N_{NN},$$

em que N_{NN} é o número de treinamentos da rede inversa (configurações de arquitetura e sementes). Para uma única configuração e semente, $N_{NN} = 1$.



Sumário

5 Estratégia de Avaliação

- ▶ Introdução e Motivação
- ▶ Definição do Problema Inverso
- ▶ Métodos de Identificação de Parâmetros
- ▶ Metodologia Experimental
- ▶ Estratégia de Avaliação
- ▶ Resultados Esperados e Desafios



Métricas de Avaliação

5 Estratégia de Avaliação

- **Erro relativo dos parâmetros:**

$$E_\theta = \frac{\left\| \hat{\boldsymbol{\theta}} - \boldsymbol{\theta}^* \right\|_2}{\left\| \boldsymbol{\theta}^* \right\|_2}.$$

- **Erro das trajetórias reconstruídas:**

$$\mathrm{RMSE} = \sqrt{\frac{1}{2m} \sum_{i=1}^{m} \left[\left(\hat{N}(t_i) - N^*(t_i) \right)^2 + \left(\hat{P}(t_i) - P^*(t_i) \right)^2 \right]}.$$

- **Estabilidade e robustez:**
  - Média e desvio-padrão dos erros em múltiplas execuções;
  - Variação do desempenho em função do ruído e da quantidade de observações.
- **Custo computacional:**
  - Tempo de treinamento e calibração;
  - Número de avaliações da função objetivo;
  - Tempo de inferência, quando aplicável.



Sumário

6 Resultados Esperados e Desafios

- ▶ Introdução e Motivação
- ▶ Definição do Problema Inverso
- ▶ Métodos de Identificação de Parâmetros
- ▶ Metodologia Experimental
- ▶ Estratégia de Avaliação
- ▶ Resultados Esperados e Desafios

Resultados Esperados

- Implementação e avaliação de diferentes técnicas de identificação de parâmetros para o modelo de Rosenzweig-MacArthur;
- Análise comparativa da **precisão, robustez e eficiência** dos métodos investigados;
- Identificação das vantagens e limitações do algoritmo genético e das abordagens baseadas em redes neurais;

Limitações e Desafios

- Possíveis dificuldades de identificabilidade e sensibilidade dos parâmetros;
- Dependência das condições iniciais e das configurações de otimização;
- Custo de treinamento das redes neurais em comparação com a resolução numérica das EDOs.



Calibração do Modelo de Rosenzweig-MacArthur com Algoritmos Genéticos e Redes Neurais

Obrigado pela atenção!
Perguntas e discussões

Lorran de Araújo Durães Soares[1] - lorran@posgrad.lncc.br