



Redes Transformers, ViTs e HQViTs

Estudos sobre Quantum AI/ML

Lorran de Araújo Durães Soares¹ - lorran@posgrad.lncc.br

¹Laboratório Nacional de Computação Científica (LNCC/MCTI)

June 18, 2026



LNCC

Laboratório Nacional de
Computação Científica



Table of Contents

1 Motivação

► Motivação

► Atenção e Transformers

► Transformers Para Imagens

► A Arquitetura HQViT

► Experimentos e Discussão

► Conclusão



O Problema

1 Motivação

Como uma rede neural entende uma imagem?

- Uma imagem possui informação local: bordas, texturas, formas e cores.
- Mas a decisão final depende também de **relações globais**: partes distantes podem estar conectadas semanticamente.
- Em classificação, queremos responder: quais regiões são mais importantes para identificar a classe?

Ideia central da apresentação: atenção permite modelar relações entre partes da entrada; o HQViT investiga se parte desse mecanismo pode ser feita com circuitos quânticos.



Table of Contents

2 Atenção e Transformers

- ▶ Motivação
- ▶ Atenção e Transformers
- ▶ Transformers Para Imagens
- ▶ A Arquitetura HQViT
- ▶ Experimentos e Discussão
- ▶ Conclusão



Intuição Do Mecanismo De Atenção

2 Atenção e Transformers

Atenção é uma forma de ponderar informação.

- Nem todos os elementos da entrada contribuem igualmente para uma decisão.
- O modelo aprende **para onde olhar** e **quanto peso dar** a cada parte.
- Em uma imagem, isso significa relacionar regiões diferentes: por exemplo, roda, farol e carroceria.

Pergunta didática: dado um elemento da entrada, quais outros elementos ajudam a interpretá-lo?



Exemplo De Atenção Em Texto

2 Atenção e Transformers

Considere a frase: “*I swam across the river to get to the other bank.*”

Queremos entender a semântica da palavra **bank**. Nesse contexto, ela significa margem do rio, não banco financeiro.

1. A frase é separada em unidades chamadas **tokens**: $t_1, t_2, \dots, t_n$.
2. Cada token é representado por um vetor numérico: $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n \in \mathbb{R}^d$.
3. O mecanismo de atenção calcula pesos $w_{i1}, w_{i2}, \dots, w_{in}$, indicando a relevância de cada token para interpretar o token i .
4. A saída é uma nova representação contextual: $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n$.

$$\mathbf{y}_i = \sum_{j=1}^n w_{ij} \mathbf{v}_j$$

Palavras como *river*, *swam* e *across* devem receber maior peso para definir o significado de *bank*.



Como calcular os pesos da atenção?

2 Atenção e Transformers

Para medir a relevância dos tokens em relação ao token i :

1. Calculamos as similaridades:

$$s_{ij} = \mathbf{v}_i^\top \mathbf{v}_j, \quad j = 1, \dots, n$$

2. Normalizamos com *softmax*:

$$w_{ij} = \frac{e^{s_{ij}}}{\sum_{k=1}^n e^{s_{ik}}}$$

3. Com isso, obtemos:

$$\sum_{j=1}^n w_{ij} = 1, \quad 0 \leq w_{ij} \leq 1$$

A representação contextual é:

$$\mathbf{y}_i = \sum_{j=1}^n w_{ij} \mathbf{v}_j$$




Figure: Esquematização do cálculo de $\mathbf{y}_i$.



Como Inserir Aprendizagem No Cálculo Dos Pesos?

2 Atenção e Transformers

No Transformer, os vetores usados na atenção não são fixos: eles são aprendidos por projeções treináveis.

$$Q = XM_Q, \quad K = XM_K, \quad V = XM_V$$

- Q e K definem **quais tokens devem se relacionar**.
- V contém a **informação que será combinada** após calcular a relevância.

Primeiro calculamos a matriz de pesos de atenção:

$$W = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)$$

Depois usamos esses pesos para combinar os valores:

$$Y = WV \quad \Rightarrow \quad \mathbf{y}_i = \sum_{j=1}^n A_{ij} \mathbf{v}_j$$

Assim, A_{ij} indica quanto o token j contribui para a representação final do token i .




Figure: Esquemática do cálculo de y_i com pesos aprendíveis.



O Que É Um Transformer?

2 Atenção e Transformers

Um **Transformer** é uma arquitetura neural que usa atenção como mecanismo principal para construir representações contextuais.

- A atenção transforma cada token em um vetor mais rico, levando em conta os outros tokens.
- O Transformer empilha vários blocos de atenção, refinando essas representações camada por camada.
- Cada bloco combina **Self-Attention**, normalização, conexões residuais e redes *feed-forward*.
- Assim, o modelo aprende não apenas relações diretas entre tokens, mas composições cada vez mais abstratas.

Ideia central: atenção diz como os elementos interagem; o Transformer organiza essas interações em uma rede profunda treinável.



Arquitetura

2 Atenção e Transformers

Transformer






Table of Contents

3 Transformers Para Imagens

- ▶ Motivação
- ▶ Atenção e Transformers
- ▶ **Transformers Para Imagens**
- ▶ A Arquitetura HQViT
- ▶ Experimentos e Discussão
- ▶ Conclusão



Como Aplicar Transformers Em Imagens?

3 Transformers Para Imagens

Transformers foram originalmente pensados para sequências. Uma imagem precisa ser transformada em sequência.

1. A imagem é dividida em pequenos blocos, chamados **patches**.
2. Cada patch é vetorizado e projetado para um **embedding**.
3. A sequência de embeddings é processada por blocos de atenção.


Assim, uma imagem passa a ser tratada como uma sequência de partes visuais.



Vision Transformer (ViT)

3 Transformers Para Imagens

Figure: Visão geral do Vision Transformer.



Fonte: [1].



Pipeline Do ViT Clássico

3 Transformers Para Imagens

1. **Divisão em patches:** a imagem $\mathbf{x} \in \mathbb{R}^{H \times W \times C}$ é dividida em T partes.
2. **Embedding linear:** cada patch vira um vetor de dimensão d .
3. **Positional Encoding:** adiciona informação de posição.
4. **Self-Attention:** compara todos os patches entre si.
5. **MLP Head:** produz a classe final.



O Gargalo Do ViT

3 Transformers Para Imagens

O custo principal está no cálculo de atenção:

$$QK^T$$

- Se há T patches, cada patch é comparado com todos os outros.
- A complexidade cresce de forma **quadrática**: $\mathcal{O}(T^2d)$.
- Imagens maiores geram mais patches e tornam o treinamento mais caro.

Pergunta central: é possível reduzir esse custo mantendo boa capacidade de representação?



Table of Contents

4 A Arquitetura HQViT

- ▶ Motivação
- ▶ Atenção e Transformers
- ▶ Transformers Para Imagens
- ▶ A Arquitetura HQViT
- ▶ Experimentos e Discussão
- ▶ Conclusão



Da Atenção Clássica À Atenção Quântica

4 A Arquitetura HQViT

No ViT clássico, a etapa cara é calcular a matriz de atenção:

$$A = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)$$

- $QK^{\top}$ mede a similaridade entre consultas e chaves.
- Essa comparação é feita para muitos pares de tokens/patches.
- O HQViT desloca essa etapa para um módulo de atenção quântica [2].

Ideia central: manter a estrutura híbrida, mas usar computação quântica no cálculo dos coeficientes de atenção.



Por Que Usar Computação Quântica Aqui?

4 A Arquitetura HQViT

A parte quântica entra como uma ferramenta para representar, transformar e comparar vetores.

- **Amplitude encoding:** codifica um vetor clássico nas amplitudes de um estado quântico.

$$|\psi\rangle = \sum_{i=0}^{2^n-1} x_i |i\rangle$$

- **Circuitos variacionais:** aplicam transformações treináveis ao estado codificado.
- **Medições:** extraem probabilidades ou similaridades para retornar ao fluxo clássico.

O objetivo não é quantumizar toda a rede, mas atacar seletivamente o bloco mais caro: a atenção.



Ideia Do HQViT

4 A Arquitetura HQViT

O **HQViT** é um Vision Transformer híbrido clássico-quântico.

- A entrada é preparada classicamente e codificada em um estado quântico.
- Circuitos variacionais fazem o papel das projeções aprendíveis de atenção.
- Similaridades entre estados quânticos geram os coeficientes de atenção.
- Camadas clássicas continuam responsáveis pelo pós-processamento e pela classificação.

Escolha de projeto: usar recursos quânticos onde há maior custo computacional, mantendo o restante da arquitetura simples.



Processamento Da Imagem Inteira

4 A Arquitetura HQViT

Diferencial chave: o módulo quântico recebe a imagem como um único estado global.

- A imagem é organizada como um **whole-image embedding** e codificada por amplitude encoding:

$$|\psi\rangle = \sum_{i=0}^{T-1} \sum_{l=0}^{d-1} x_{i,l} |i\rangle |l\rangle$$

- O estado tem dois subsistemas: $|i\rangle$ guarda o **índice do token/patch**; $|l\rangle$ guarda a **informação interna** daquele token.
- Os circuitos U_Q e U_K transformam o estado global, mas a medição usa os índices i e j para extrair relações entre tokens.
- Assim, a atenção estima scores para pares de tokens:

$$a_{ij} = |\langle q_i | k_j \rangle|^2$$

O circuito vê a imagem inteira, mas a matriz de atenção continua descrevendo relações entre tokens/patches, não relações pixel-a-pixel.



Q , K e V Como Circuitos Variacionais

4 A Arquitetura HQViT

No Transformer clássico, matrizes treináveis geram Q , K e V a partir da entrada. No HQViT, esse papel é assumido por circuitos quânticos parametrizados:

$$|\psi_Q\rangle = U_Q|\psi\rangle, \quad |\psi_K\rangle = U_K|\psi\rangle, \quad |\psi_V\rangle = U_V|\psi\rangle$$

- U_Q , U_K e U_V são circuitos variacionais treináveis.
- Eles transformam a representação global da imagem em estados análogos a Query, Key e Value.
- Os parâmetros dos circuitos são ajustados durante o treinamento do modelo híbrido.

Assim, a parte quântica substitui as projeções lineares da atenção por transformações treináveis em estados quânticos.



Quantum Self-Attention: O Que Comparar?

4 A Arquitetura HQViT

A atenção precisa medir quanto o token j é relevante para o token i .

- No Transformer clássico, isso vem de uma similaridade entre q_i e k_j .
- No HQViT, q_i e k_j são estados quânticos:

$$|q_i\rangle \quad \text{e} \quad |k_j\rangle$$

- A similaridade desejada é o overlap entre esses estados:

$$a_{ij} = |\langle q_i | k_j \rangle|^2$$

Problema: esse produto interno não pode ser lido diretamente de um computador quântico.



SWAP Test: A Ideia Da Ancilla

4 A Arquitetura HQViT

O **SWAP Test** usa um qubit auxiliar, chamado **ancilla**, para estimar se dois estados são parecidos.

- A ancilla começa em $|0\rangle$ e não representa imagem, patch ou classe.
- Ela funciona como um “sensor” da similaridade entre $|q_i\rangle$ e $|k_j\rangle$.
- O circuito cria uma correlação entre a ancilla e o efeito de trocar os dois estados.
- Se trocar os estados quase não muda o sistema, eles são parecidos.

A medição da ancilla não retorna a similaridade em uma única execução: ela retorna apenas 0 ou 1. A similaridade aparece na **frequência** com que o resultado 0 ocorre.



SWAP Test: Passo A Passo

4 A Arquitetura HQViT

Para comparar $|q_i\rangle$ e $|k_j\rangle$, o circuito aplica:

1. **Preparação:** começamos com

$$|0\rangle|q_i\rangle|k_j\rangle$$

onde o primeiro qubit é a ancilla.

2. **Hadamard na ancilla:** coloca a ancilla em superposição.
3. **Controlled-SWAP:** se a ancilla está em $|1\rangle$, troca $|q_i\rangle$ e $|k_j\rangle$.
4. **Novo Hadamard:** faz as duas possibilidades interferirem.
5. **Medição:** mede apenas a ancilla, obtendo 0 ou 1.

Essa interferência converte a similaridade entre os estados em uma probabilidade mensurável.



Estimando $P(0)$ Por Repetição

4 A Arquitetura HQVIT

Uma execução do circuito produz apenas uma amostra:

$$\text{ancilla} \in \{0, 1\}$$

Por isso, repetimos o mesmo circuito muitas vezes, chamadas **shots**.

- Se rodamos S shots e a ancilla sai como 0 em N_0 deles, estimamos:

$$P(0) \approx \frac{N_0}{S}$$

- Em simulações e hardware real, S pode ser escolhido conforme precisão e custo.
- Valores comuns são da ordem de centenas a milhares de shots, por exemplo $S = 1000$ ou $S = 10000$.

Quanto maior S , menor o ruído estatístico da estimativa, mas maior o custo de execução.



Do SWAP Test Ao Score De Atenção

4 A Arquitetura HQViT

O SWAP Test é construído para que a probabilidade $P(0)$ satisfaça:

$$P(0) = \frac{1 + |\langle q_i | k_j \rangle|^2}{2}$$

- Se $|q_i\rangle$ e $|k_j\rangle$ são iguais, então $|\langle q_i | k_j \rangle|^2 = 1$ e $P(0) = 1$.
- Se são ortogonais, então $|\langle q_i | k_j \rangle|^2 = 0$ e $P(0) = 0.5$.
- Logo, podemos recuperar a similaridade por:

$$a_{ij} = |\langle q_i | k_j \rangle|^2 = 2P(0) - 1$$

Esse a_{ij} entra na matriz de atenção como o score quântico entre os tokens i e j .



Como O Score Quântico Entra Na Atenção?

4 A Arquitetura HQViT

Depois de estimar os scores quânticos, o restante da atenção segue a mesma lógica do Transformer.

$$\alpha_{ij} = \frac{e^{a_{ij}}}{\sum_{m=1}^n e^{a_{im}}}$$


$$\mathbf{y}_i = \sum_{j=1}^n \alpha_{ij} \mathbf{v}_j$$

- A parte quântica estima as relações entre tokens.
- O softmax normaliza essas relações como pesos de atenção.
- Os pesos combinam os valores V e retornam uma representação clássica para as próximas camadas.



Arquitetura e Fluxo Híbrido

4 A Arquitetura HQViT



Fonte: [2].

Imagem $\rightarrow |\psi\rangle \rightarrow$ Atenção quântica $\rightarrow$ Classe

- Preparação e classificação continuam clássicas.
- O módulo quântico calcula os coeficientes de atenção.
- O modelo combina otimização clássica com circuitos treináveis.



Table of Contents

5 Experimentos e Discussão

- ▶ Motivação
- ▶ Atenção e Transformers
- ▶ Transformers Para Imagens
- ▶ A Arquitetura HQViT
- ▶ Experimentos e Discussão
- ▶ Conclusão



Datasets e Simulação

5 Experimentos e Discussão

Datasets reportados no trabalho:

- **MNIST**: benchmark principal de dígitos manuscritos.
- **Fashion-MNIST**: imagens simples, mas mais desafiadoras semanticamente.
- **CIFAR-10**: usado em versões redimensionadas para reduzir custo quântico.

Ferramentas: simulações com PennyLane e backends como `default.qubit`, além de testes considerando ruído.



Vantagens Potenciais

5 Experimentos e Discussão

- **Eficiência de parâmetros:** VQCs podem representar transformações expressivas com poucos parâmetros.
- **Atenção global:** o modelo explora uma representação quântica da imagem inteira.
- **Hibridização seletiva:** usa computação quântica apenas onde ela pode trazer benefício.
- **Resultados promissores:** o paper reporta ganhos em benchmarks como MNIST frente a baselines quânticos.



Limitações e Cuidados

5 Experimentos e Discussão

- **Ruído quântico:** hardware NISQ ainda sofre com erros de portas e medições.
- **Preparação de estado:** amplitude encoding é compacto em qubits, mas pode ser caro em profundidade de circuito.
- **Escalabilidade:** imagens grandes exigem circuitos maiores e mais difíceis de simular.
- **Tempo de execução:** hardware quântico atual ainda é lento para inferência em larga escala.



Table of Contents

6 Conclusão

- ▶ Motivação
- ▶ Atenção e Transformers
- ▶ Transformers Para Imagens
- ▶ A Arquitetura HQViT
- ▶ Experimentos e Discussão
- ▶ Conclusão



Conclusão

6 Conclusão

Mensagem principal:

- Atenção permite modelar relações entre partes da entrada.
- ViTs aplicam esse princípio a imagens, mas sofrem com custo quadrático.
- O HQViT propõe substituir parte da atenção por circuitos quânticos variacionais.
- A abordagem é promissora, mas ainda experimental e limitada pelo hardware atual.

Trabalhos futuros: explorar segmentação semântica, sensoriamento remoto e treinamento consciente de hardware.



References

6 Conclusão

 Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, et al.

An image is worth 16x16 words: Transformers for image recognition at scale.

arXiv preprint arXiv:2010.11929, 2020.

 Hui Zhang, Qinglin Zhao, Mengchu Zhou, and Li Feng.

Hqvit: Hybrid quantum vision transformer for image classification.

arXiv preprint arXiv:2504.02730, 2025.

Obrigado!

Perguntas e discussões

HQViT: Hybrid Quantum Vision Transformer for Image Classification
Análise de abordagens híbridas clássico-quânticas aplicadas a imagens

Lorran de Araújo Durães Soares
lorran@posgrad.lncc.br